

IL PUNTO DI PARTENZA


Il progetto, in parole semplici

Come aiutare un modello a riprendere un'attività dopo più conversazioni.

Un **LLM** è un modello che comprende e genera testo. Per rispondere usa il testo che riceve in quel momento: il suo **contesto**. Una conversazione passata può essere salvata da qualche parte senza essere presente nel contesto della nuova risposta.

Il progetto studia una **memoria esterna**: un archivio fuori dal modello, dal quale scegliere informazioni utili. I pesi del modello non vengono modificati. L'idea è simile a consultare un quaderno prima di rispondere. Le survey di Zhang e Du aiutano a descrivere questo meccanismo. [\[1\]](#) [\[2\]](#)

Un esempio per capire il problema



Risposta corretta: il rapporto deve ancora restare interno. Il nuovo aggiornamento tecnico non annulla quel vincolo. Per rispondere bene servono informazioni di conversazioni diverse.

Figura 1. Esempio didattico inventato, non una prova sperimentale.

Le domande che guidano il lavoro

RQ1 - Quanto? Che cosa cambia se il modello può cercare solo nella conversazione corrente oppure in tutte quelle dello stesso caso?

RQ2 - Come? A parità di conversazioni accessibili, che cosa cambia se si conservano messaggi interi, fatti, aggiornamenti o relazioni?

Obiettivo pratico: capire se il sistema ricorda ciò che serve, distingue il nuovo dal superato e sa dire «non ho questa informazione». I casi di cybersecurity offrono situazioni concrete da seguire nel tempo.

IL FUNZIONAMENTO

Dal messaggio alla risposta

La memoria richiede tre attività: **scrivere, gestire e leggere**. Scrivere significa salvare informazioni; gestire significa organizzarle e aggiornarle; leggere significa recuperare quelle utili. [1] [2]




Figura 2. Il modello che risponde vede soltanto il contesto selezionato.

Che cosa significa RAG?

RAG significa recuperare informazioni e poi usarle per generare una risposta. Nel progetto la ricerca di base confronta le parole della domanda con quelle dei messaggi o dei fatti. Il metodo si chiama **TF-IDF con similarità coseno**: assegna un punteggio di somiglianza lessicale.

Un esempio del limite: «Quali azioni sono concluse?» e «La password è stata reimpostata» possono parlare della stessa cosa senza condividere parole utili alla ricerca. Il fatto può quindi restare fuori dal contesto.

Come si controlla se il sistema funziona?

Per ogni domanda si prepara una scheda con risposta attesa, fatti necessari e messaggi che li dimostrano. Questa scheda si chiama **oracle**. Serve alla valutazione e non viene mostrata al modello. LongMemEval aiuta a distinguere recupero dell'informazione e uso nella risposta. [4]

- | | |
|---------------------|--|
| Disponibile? | Il fatto esiste nelle conversazioni a cui il sistema può accedere? |
| Recuperato? | Il contenuto necessario è davvero nel testo passato al modello? |
| Usato bene? | La risposta riporta tutti i fatti richiesti, senza aggiungerne di inventati? |

Attenzione: citare il messaggio giusto non basta. Un fatto estratto da quel messaggio può aver perso proprio il dettaglio necessario. Si controlla il contenuto, oltre alla provenienza.

LE CINQUE ORGANIZZAZIONI DELLA MEMORIA

Che cosa viene conservato?

Le sigle sono nomi brevi delle strategie del progetto. I paper forniscono idee, adattate qui in forma semplice.

T**Turn-level RAG**

Conserva e recupera **messaggi originali interi**. Mantiene insieme dettagli e spiegazioni, ma può portare nel contesto testo poco utile. LoCoMo confronta anche il recupero di turni di dialogo. [3]

F**Fact-based RAG**

Trasforma i messaggi in **fatti brevi**, indicando da dove provengono. È più selettiva, ma l'estrazione può perdere o alterare un dettaglio. I fatti vecchi restano accanto ai nuovi. Riferimenti: LoCoMo e Mem0. [3] [5]

U**Fact-based RAG con aggiornamenti**

Parte dagli stessi fatti e decide se **aggiungere, aggiornare, ritirare o lasciare invariato**. Sono le operazioni ADD, UPDATE, DELETE e NOOP, ispirate a Mem0. Le vecchie versioni restano riconoscibili nello storico. [5]

G**Graph-based Memory**

Parte dai fatti aggiornati e aggiunge **entità e relazioni**: per esempio, una persona apre un link e usa un account. Cerca anche collegamenti. Mem0 con grafo e A-MEM ispirano aspetti diversi di questa scelta. [5] [6]

GER**Memoria gerarchica**

Riusa la memoria aggiornata, separando **informazioni recenti e archivio**. «Recente» significa creata o aggiornata nelle ultime due sessioni. Cerca in entrambi i gruppi. L'ispirazione ai livelli viene da MemGPT. [7]

SC05 - GER: memoria nel contesto, budget totale 200 token

100: memoria recente

100: archivio

Figura 3. Lo spazio inutilizzato può passare all'altro gruppo. Una voce entra intera oppure resta fuori. **Vecchio non significa superato**: una decisione lontana può essere ancora valida.

Una distinzione utile: GER usa regole fissate dal progetto; in MemGPT il modello può gestire la memoria tramite strumenti. Questi sistemi non sono repliche complete dei paper.

Fonti: RQ2.md e MEMORIA_GERARCHICA.md. I numeri di GER usano il conteggio locale del progetto.

LE PROVE

Prima «quanto», poi «come»

RQ1: quante conversazioni sono accessibili?

Il **pilot**, cioè la prova preliminare, usa due scenari: un incidente informatico e un problema nel recupero password. Ogni scenario ha quattro conversazioni e sette domande. Cambia soltanto l'insieme dei messaggi in cui cercare; la ricerca resta uguale e seleziona al massimo due messaggi.

Risposte complete su 14 domande



Figura 4. Risultati del pilot RQ1; non sono risultati di RQ2.

Che cosa si osserva: nella prova, aprire l'accesso alle altre sessioni permette più risposte complete. C0 si astiene correttamente in tutte le 14 domande: è prudente, ma non riesce a fornire i fatti richiesti. C2 trova le informazioni per molte più risposte, ma non risolve tutto.

RQ2: stessi casi, modi diversi di ricordare

Le prove principali usano casi sintetici, cioè costruiti apposta: recupero password, infezione malware, truffa via SMS e un caso più lungo di nove sessioni. Le domande richiedono obiettivi, aggiornamenti, attività concluse o aperte, collegamenti e informazioni mancanti. LoCoMo e LongMemEval sono riferimenti per questo tipo di valutazione. [3] [4]

Il limite di 200 token vale soltanto per SC05, nelle strategie Turn-level RAG, Fact-based RAG con aggiornamenti e Memoria gerarchica. **SC02, SC03 e SC04 non hanno un tetto sperimentale al contesto recuperato.** In SC05 il conteggio locale include testo, etichette, stato e provenienza; esclude domanda e istruzioni comuni. Non coincide con il conteggio del fornitore del modello.

Per rendere leggibile il confronto: stesse domande e conversazioni, stesso modello registrato nelle prove RQ2 (Claude Sonnet 5, effort medium), stesse istruzioni di risposta. La memoria viene costruita senza vedere le risposte attese; ogni domanda parte dallo stesso stato salvato.

Numeri RQ1: metrics_pilot.md e metrics_pilot.json. RQ2: configurazioni e scenari locali.

I RISULTATI DISPONIBILI

RQ2: leggere un caso alla volta

La tabella conta risposte complete e supportate: tutti i fatti richiesti, senza aggiunte non sostenute dalle conversazioni.

Configurazione di riferimento: SC02, SC03 e SC04 sono senza tetto sperimentale; il budget di **200 token** si applica solo a SC05. La tabella riporta i risultati aggiornati di SC02-SC04 e mantiene invariati quelli di SC05. Ogni strategia risponde a sette domande dello stesso scenario.

Scenario	Strategia	Limite del contesto	Complete e supportate
SC02 Password	Turn-level RAG	Nessun tetto	5/7
	Fact-based RAG	Nessun tetto	3/7
SC03 Malware	Fact-based RAG	Nessun tetto	1/7
	Fact-based RAG con aggiornamenti	Nessun tetto	1/7
SC04 Truffa via SMS	Turn-level RAG	Nessun tetto	4/7
	Fact-based RAG con aggiornamenti	Nessun tetto	3/7
	Graph-based Memory	Nessun tetto	3/7
SC05 Caso lungo	Turn-level RAG	200 token	3/7
	Fact-based RAG con aggiornamenti	200 token	2/7
	Memoria gerarchica	200 token	1/7

Come leggere 5/7: cinque risposte complete e supportate su sette domande. Una domanda per scenario riguarda un’informazione assente: l’astensione è corretta, ma non entra nel conteggio. In queste prove l’astensione prevista è riuscita in ogni modalità.

Senza tetto, la ricerca continua a selezionare. In SC02-SC04 un fatto può ancora restare fuori perché non risulta pertinente alla domanda o non è ammesso dalle regole della memoria. Le strategie possono quindi ricevere quantità di testo diverse. In SC05, invece, condividono il limite di 200 token.

FULL_HISTORY - controllo diagnostico

Fornisce tutta la cronologia in ordine, senza selezione né budget, anche in SC05. Risultati riusati: SC02 6/7, SC03 5/7, SC04 4/7, SC05 6/7. Aiuta a capire gli errori e può sbagliare anch’esso; resta separato dalle strategie con recupero.

Fonti: budget_per_scenario_v1 per SC02-SC04; scheda SC05 per T/U/GER. FULL_HISTORY riusato. Giudizi in parte proposti.

IL SIGNIFICATO DEL LAVORO

Che cosa bisogna capire davvero

Tre errori concreti spiegano il progetto

1. Un fatto può cambiare prima della risposta.

Su SC02, una data non presente nei messaggi viene aggiunta durante l'estrazione dei fatti. Il modello la ripete. Per trovare l'errore bisogna controllare anche ciò che è stato scritto nella memoria.

2. Un fatto salvato può non essere recuperato.

Nella prova senza tetto, su SC04 alcune azioni concluse restano fuori perché non condividono parole utili con la domanda. Aumentare lo spazio non cambia quel punteggio di ricerca.

3. Anche con tutta la storia si può rispondere male.

Nel controllo FULL_HISTORY di SC04, il modello riceve tutti i messaggi ma in una risposta omette un passaggio della catena di eventi e aggiunge un'affermazione non supportata. Avere l'informazione nel contesto non garantisce che venga usata bene.

L'idea centrale: un fatto deve essere conservato bene, rimanere valido, essere recuperato e poi usato bene. Guardare soltanto la risposta finale nasconde dove il processo si è fermato.

Quanto sono solide queste conclusioni?

Sono **risultati di sviluppo**: pochi casi e una sola generazione per domanda e modalità. SC02-SC04 usano le risposte senza tetto; SC05 e FULL_HISTORY riusano risposte già disponibili. Non permettono una classifica generale delle architetture; i confronti vanno letti dentro ciascuno scenario.

I giudizi di SC02-SC04 attendono revisione. In SC05 sono approvate dallo studente le classi di U, GER e FULL_HISTORY; i giudizi di T e le valutazioni aggiunte sul supporto restano proposti. Il protocollo non è congelato e SC01, previsto per RQ2, non è stato eseguito.

RQ3: la direzione discussa, ancora da precisare

La possibile terza domanda riguarda la **confusione tra attività dello stesso dominio**. Esempio: si alternano conversazioni sul caso A e sul caso B, con azioni simili. Se si chiede «Che cosa resta da fare nel caso A?», il sistema deve usare i fatti di A senza importarli da B.

È una direzione ripresa dalla discussione del 19 settembre. Nei file esaminati non è presente un protocollo RQ3 completo: servono casi, domande, risposte attese e criteri fissati prima delle prove. Qui non le vengono attribuiti risultati.

Il progetto in una frase: studiare come l'accesso alle conversazioni e il modo di organizzarle aiutano un modello a continuare un'attività, osservando sia le risposte sia i punti in cui la memoria perde utilità.

PER ORIENTARSI NELLA LETTERATURA

I paper e il loro ruolo

I numeri nel testo sono cliccabili. Sono riferimenti alle idee utilizzate, non risultati del progetto.

[1] **Zeyu Zhang et al. (2024).** *A Survey on the Memory Mechanism of Large Language Model based Agents.*

Dà le parole per descrivere fonti, forme e operazioni della memoria.

[2] **Pengfei Du (2026).** *Memory for Autonomous LLM Agents: Mechanisms, Evaluation, and Emerging Frontiers.*

Collega scrittura, gestione, lettura e valutazione in un unico quadro.

[3] **Maharana et al. (2024).** *Evaluating Very Long-Term Conversational Memory of LLM Agents (LoCoMo).*

Ispira prove distribuite tra conversazioni e il confronto tra messaggi e osservazioni.

[4] **Wu et al. (ICLR 2025).** *LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory.*

Aiuta a separare recupero e lettura, includendo aggiornamenti e astensione.

[5] **Chhikara et al. (2025).** *Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory.*

Ispira fatti compatti, operazioni di aggiornamento e rappresentazione a grafo.

[6] **Xu et al. (2025).** *A-MEM: Agentic Memory for LLM Agents.*

Mostra note collegate e memoria che evolve; è un'ispirazione, non il grafo qui riprodotto.

[7] **Packer et al. (2023; versione 2024).** *MemGPT: Towards LLMs as Operating Systems.*

Ispira la distinzione fra contesto e livelli di memoria esterna.

Gli altri lavori delle tue sintesi

[8] **Park et al. (2023).** *Generative Agents: Interactive Simulacra of Human Behavior.* Memoria, riflessione e pianificazione in agenti simulati.

[9] **Wang et al. (2023).** *Augmenting Language Models with Long-Term Memory (LongMem).* Usa rappresentazioni interne e una rete aggiuntiva da addestrare.

[10] **Zhehao Zhang et al. (2024).** *Personalization of Large Language Models: A Survey.* Inquadra adattamento alle preferenze e alle informazioni dell'utente.

Questi tre lavori allargano il contesto teorico. Le loro funzioni non fanno parte delle cinque strategie confrontate qui.

Da dove vengono i dati di questa guida

Le tue due sintesi PDF hanno orientato la spiegazione; titoli e collegamenti sono stati verificati sulle pagine dei paper. Per il progetto sono stati letti EXPERIMENT.md, RQ2.md, MEMORIA_GERARCHICA.md, le metriche del pilot, le schede di RACCOLTA_RISULTATI e la prova budget_per_scenario_v1. I conteggi della pagina 5 sono ricavati dai file di valutazione. Le figure sono originali e schematiche.